

VLM Planning：阶段进展、诊断实验与训练方案

Abstract

在前两天，我已经完成了整体训练计划的撰写，并且完成了完整的数据—训练—评测 pipeline 初版代码的实现。在确定整体 pipeline 可行后，进行了小规模 500 条输入训练测试，并且生成了 10 万条数据

目前 1 万条输入的训练正在进行，我会在完成后汇报并根据结果调整后继续 scale up

以下是经过试错和小型实验测试后我目前的训练设定，在后文有详细选择特定设置的解释

模型输入：

1. system turn：系统 prompt + 输出格式示例
2. user turn：一张室内图片 + 一句模糊的 prompt

模型输出：

1. state：空间状态认知
2. plan：高层 Subgoal Planning
3. action：固定 JSON 格式的动作步骤
4. 自然语言规划过程

训练数据：

使用 AI2-THOR / ProcTHOR 生成室内场景的图片

训练设置：

1. 使用 ms-swift 框架在单卡上训练 Qwen3.5 0.8B 模型，采用全量微调
2. 要求模型显式输出 CoT，并且对 CoT 和最终固定 JSON 格式的输出进行 SFT，loss 权重暂定为 0.3 / 0.3 / 0.4

Evaluation :

采用生成的数据进行in domain评测，用EmbSpatial-Bench进行OOD的benchmark

实验分析与设计决策

模型输入

考虑到模型输出不合格/loss大的原因可能是 1. 无法理解任务 2. 感知能力不足 3.空间理解能力不足 4. 规划能力不足 5.输出格式不合格

为了避免1、5两个问题，我用200条数据（image+instruction+state+plan+action），分成七组条件测试Action Seq EM和Step Match两个指标

实际组	给模型的输入
A'	不相关图像 + 正确 instruction
A	正确图像 + 正确 instruction
B-natural	自然语言 scene graph + instruction，无图
B-JSON	JSON scene graph + instruction，无图
B-triples	三元组 scene graph + instruction，无图
C	正确图像 + instruction + gold spatial facts
D	正确图像 + instruction + gold subgoal

结果发现全部接近0

条件	输入	Action Seq EM	Step Match	结构合法率
A'	错图 + instruction	0%	0%	0.42%
A	正确图 + instruction	0%	0%	2.08%
B-JSON	JSON scene graph + instruction	0%	0%	0.42%
B-natural	自然语言 scene graph + instruction	0%	0%	0%
B-triples	triples scene graph + instruction	0%	0%	0.83%

条件	输入	Action Seq EM	Step Match	结构合法率
C	图 + instruction + gold spatial facts	0%	0%	24.17%
D	图 + instruction + gold subgoal	0%	0%	58.75%

我检查了模型在测试里实际的输入输出，结果发现模型能理解要做什么，但是输出的JSON格式不合法或者会复制prompt的内容，因此我又统计了结构合法率，结果发现普遍非常低

于是我重构了模型输入，完善并加入了系统prompt+输出格式示例，以下是新输入的结果，模型的输出合法率接近100%

条件	Action Seq EM	Step Match	成功解析动作
A' 错图 + instruction	0.00%	0.51%	98.68%
A 正确图 + instruction	0.88%	2.56%	99.12%
B-JSON scene graph(JSON)	2.19%	18.86%	100%
B-natural scene graph(自然语言)	1.75%	19.53%	100%
B-triples scene graph(三元组)	0.88%	18.48%	100%
C 图 + gold spatial facts	1.75%	14.56%	98.25%
D 图 + gold subgoal	83.77%	90.23%	100%

模型输出：

由上表A组和B组Step Match的比较可以发现，在给出物品间空间相对状态后，模型输出准确率提升了一个数量级，说明模型的空间状态认知能力不足；比较B，C和D组后可得，尽管模型掌握了正确的空间状态认知，但是其自行规划的Step Match正确率仍只有0.2，在给出正确规划后接近0.9，说明模型的规划能力不足；D组Step Match正确率接近1，说明模型对从规划转换为格式输出掌握优秀

基于模型1. 空间状态认知能力不足 2. 规划能力不足，需要训练一个模型掌握 perception → reasoning → planning → action 多个能力，我计划采用显式 intermediate reasoning supervision，要求模型输出CoT，即state：空间状态认知和plan：高层 Subgoal Planning两部分，并且对这两部分和原版要求的action：固定JSON格式的动作步骤三者同时进行SFT，并且以固定比例分配loss权重

训练数据

首先根据需求，我明确了需要VQA的数据集，排除了trajectory data的选择。而VQA和trajectory data的数据场景选择十分有限，生态主要集中在室内和室外自动驾驶相关两部分，而且上次沟通举的两个例子都是室内场景，因此室内VQA是自然的选择。

明确筛选条件后我比较了ALFRED, ECoT (Bridge V2), EmbodiedBench EB-Alfred/Habitat, RREP, EgoThink planning等数据集，认为它们都不符合我要求的VQA，有planning监督标签的要求，因此选择使用AI2-THOR / ProcTHOR 生成室内场景的图片，并且附带ground truth的规划标签

同时，我设置了相同prompt，几乎相同图片，只有关键配置不同的成对数据生成，检测模型是否真正利用视觉信息。

此外，经过多组数据生成比对测试，我确定8个shard worker并发生成在单卡机上是生成速度最快且不会抢占CPU的设置，并以此配置执行生成10万条输入数据

训练设置

在查阅资料后发现，Qwen系列模型存在成熟的模型训练生态，可以采用ms-swift, LLaMA-Factory, Hugging Face Transformers + TRL + PEFT, Axolotl, Unsloth, Megatron-LM, verl等框架，其中自带训练优化配置，因此我决定采用ms-swift

原本微调方式暂定LoRA，但是考虑到Qwen3.5 0.8B的模型架构特殊，不是标准的纯dense Transformer：18/24 层是 GatedDeltaNet，如果照普通 Qwen 的 q_proj/k_proj/v_proj/... 配置，token mixer 只会覆盖 6/24 层。而0.8B的参数量较小，全量微调并不要求太高显存，因此

决定采用全量微调。同时考虑到参数量较小，冻结训练也不是很有性价比

Evaluation

采用生成的数据进行in domain评测，用EmbSpatial-Bench进行OOD的benchmark
目前这部分还等待进一步完善